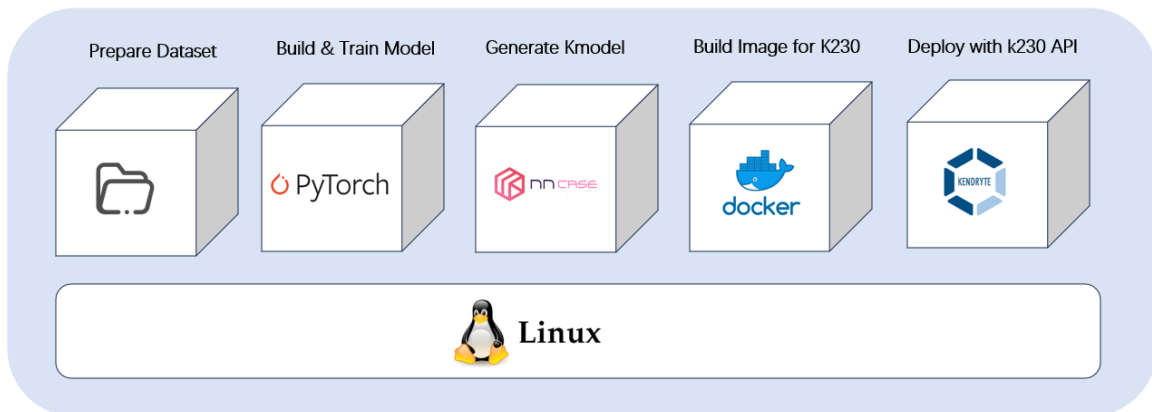


k230图像分类教程

简介

K230芯片是嘉楠科技 Kendryte®系列AIoT芯片中的最新一代SoC产品。该芯片采用全新的多异构单元加速计算架构，集成了2个RISC-V高效计算核心，内置新一代KPU（Knowledge Process Unit）智能计算单元，具备多精度AI算力，广泛支持通用的AI计算框架，部分典型网络的利用率超过了70%。

该芯片同时具备丰富多样的外设接口，以及2D、2.5D等多个标量、向量、图形等专用硬件加速单元，可以对多种图像、视频、音频、AI等多样化计算任务进行全流程计算加速，具备低延迟、高性能、低功耗、快速启动、高安全性等多项特性。



本教程将介绍如何使用PyTorch训练图像分类AI模型，并将模型转换为kmodel格式，在嘉楠 Kendryte230芯片上部署该模型。

实现该过程需要具备python和C++编程的基础知识，了解linux系统的简单操作，了解一定的深度学习知识，但并不是必须的。

本教程将实现从数据准备、模型训练和测试、k230镜像编译烧录、C++示例代码编译可执行文件、PC端和K230之间网络配置和文件传输、k230端部署的全流程过程。操作系统为linux操作系统，深度学习框架选择PyTorch实现。

本教程选择蔬菜分类场景作为示例项目。

环境说明

显卡环境

本教程默认使用CUDA的用户已经安装好合适的显卡驱动，且已搭建好CUDA环境。

安装anaconda

如果已安装anaconda或miniconda，请忽略此步骤。

anaconda用于创建虚拟环境，将PyTorch模型训练环境和其他环境隔离。

```
1 apt-get install -y wget
2 wget https://repo.anaconda.com/archive/Anaconda3-5.3.0-Linux-x86_64.sh #可以选择
  合适的版本安装
3 chmod +x Anaconda3-5.3.0-Linux-x86_64.sh
4 ./Anaconda3-5.3.0-Linux-x86_64.sh
```

出现如下界面：

```

root@dev-wyf-react:~/Downloads# ls
Anaconda3-5.3.0-Linux-x86_64.sh
root@dev-wyf-react:~/Downloads# chmod +x Anaconda3-5.3.0-Linux-x86_64.sh
root@dev-wyf-react:~/Downloads# ./Anaconda3-5.3.0-Linux-x86_64.sh

Welcome to Anaconda3 5.3.0

In order to continue the installation process, please review the license
agreement.
Please, press ENTER to continue
>>> 

```

点击Enter(回车键)

此时显示Anaconda的信息，并且会出现More，继续按Enter，直到如下图所示：

```

Anaconda Distribution contains open source software packages from third parties. These are available on an "as is" basis and subject to their individual license agreements.
These licenses are available in Anaconda Distribution or at http://docs.anaconda.com/anaconda/pkg-docs. Any binary packages of these third party tools you obtain via Anaconda Distribution are subject to their individual licenses as well as the Anaconda license. Anaconda, Inc. reserves the right to change which third party tools are provided in Anaconda Distribution.

In particular, Anaconda Distribution contains re-distributable, run-time, shared-library files from the Intel(TM) Math Kernel Library ("MKL binaries"). You are specifically authorized to use the MKL binaries with your installation of Anaconda Distribution. You are also authorized to redistribute the MKL binaries with Anaconda Distribution or in the conda package that contains them. Use and redistribution of the MKL binaries are subject to the licensing terms located at https://software.intel.com/en-us/license/intel-simplified-software-license. If needed, instructions for removing the MKL binaries after installation of Anaconda Distribution are available at http://www.anaconda.com.

Anaconda Distribution also contains cuDNN software binaries from NVIDIA Corporation ("cuDNN binaries"). You are specifically authorized to use the cuDNN binaries with your installation of Anaconda Distribution. You are also authorized to redistribute the cuDNN binaries with an Anaconda Distribution package that contains them. If needed, instructions for removing the cuDNN binaries after installation of Anaconda Distribution are available at http://www.anaconda.com.

Anaconda Distribution also contains Visual Studio Code software binaries from Microsoft Corporation ("VS Code"). You are specifically authorized to use VS Code with your in
--More--

```

输入 yes

```

Do you accept the license terms? [yes|no]
[no] >>>
Please answer 'yes' or 'no':
>>>
Please answer 'yes' or 'no':
>>> yes

Anaconda3 will now be installed into this location:
/root/anaconda3

- Press ENTER to confirm the location
- Press CTRL-C to abort the installation
- Or specify a different location below

[/root/anaconda3] >>> 

```

继续点击 Enter

```

Anaconda3 will now be installed into this location:
/home/wangke/anaconda3

- Press ENTER to confirm the location
- Press CTRL-C to abort the installation
- Or specify a different location below

[/home/wangke/anaconda3] >>>
PREFIX=/home/wangke/anaconda3
installing: python-3.6.4-hc3d631a_1 ...
Python 3.6.4 :: Anaconda, Inc.
installing: ca-certificates-2017.08.26-h1d4fec5_0 ...

```

输入 yes，添加环境变量

检查是否安装成功：

```
1 | conda -v
```

若返回conda版本，表示安装成功。

安装docker

若已安装docker，请忽略此步骤。

Docker官方和国内daocloud都提供了一键安装的脚本，使得Docker的安装更加便捷。

官方的一键安装方式：

```
1 | curl -fSSL https://get.docker.com | bash -s docker --mirror Aliyun
```

国内 daocloud一键安装命令：

```
1 | curl -SSL https://get.daocloud.io/docker | sh
```

执行上述任一条命令，耐心等待即可完成Docker的安装。

创建模型训练环境

```
1 | # 使用anaconda创建模型训练的虚拟环境
2 | conda create -n myenv python=3.9
3 | # 激活虚拟环境
4 | conda activate myenv
5 | # 按照项目内的requirements.txt安装训练所用的python库,等待安装
6 | pip install -r requirements.txt
```

在requirements.txt中会安装模型转换的包nncase和nncase-kpu，`nncase`是一个为AI加速器设计的神神经网络编译器，参考[nncase](#)。

安装dotnet

```
1 | wget https://packages.microsoft.com/config/ubuntu/20.04/packages-microsoft-
   | prod.deb -O packages-microsoft-prod.deb
2 | dpkg -i packages-microsoft-prod.deb
3 | apt update
4 | apt install -y apt-transport-https
5 | apt install -y dotnet-sdk-7.0
```

添加nncase插件到环境变量

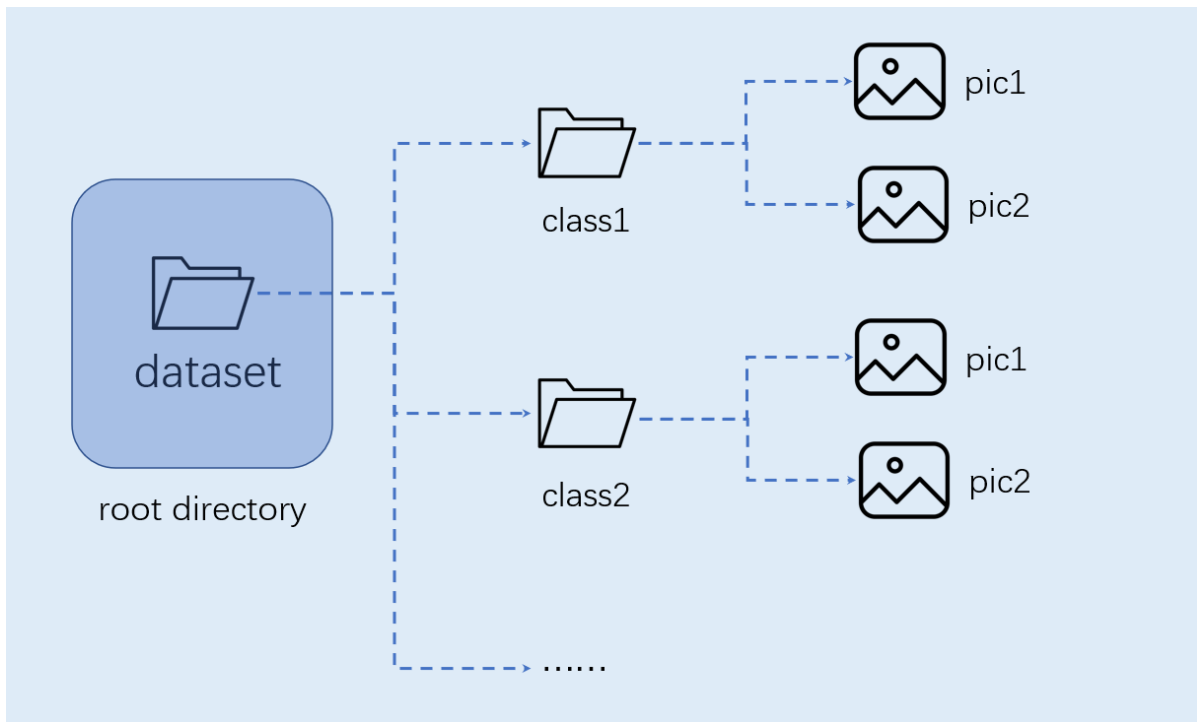
注意：此步骤需要根据个人机器中实际情况完成。如果使用anaconda虚拟环境，在anaconda安装位置下的envs目录下，选择为训练创建的虚拟环境myenv，在其下面选择lib/python3.9/site-packages/，也就是pip安装requirements.txt内nncase和nncase-kpu的安装位置。source后会退出当前虚拟环境，需要再次激活。如果直接使用机器上的python，则需要添加其下的lib/python3.9/site-packages/。具体python版本自己控制。

```
1 | # python安装路由自己机器实际情况修改
2 | export NNCASE_PLUGIN_PATH=$NNCASE_PLUGIN_PATH:/usr/local/lib/python3.9/site-
   | packages/
3 | export PATH=$PATH:/usr/local/lib/python3.9/site-packages/
4 | source /etc/profile
5 | conda activate myenv
```

使用自定义数据集训练模型

组织数据

图像分类任务自定义数据集按照如下格式组织，根目录下包括：以类别名称命名的子目录，子目录中是其类别的所有图像样本。



配置训练参数

给出的训练脚本中配置文件config.yaml设置如下：

```
1 dataset:
2   root_folder: ../data/veg_cls # 分类数据集路径
3   split: true # 是否重新执行拆分，第一次执行必须为true
4   train_ratio: 0.7 # 训练集比例
5   val_ratio: 0.15 # 验证集比例
6   test_ratio: 0.15 # 测试集比例
7
8 train:
9   device: cuda
10  txt_path: ../gen # 拆分过程生成的训练集、验证集、测试集txt文件，标签名称文件、校正集文件
11  image_size: [ 224,224 ] # 分辨率
12  mean: [ 0.485, 0.456, 0.406 ]
13  std: [ 0.229, 0.224, 0.225 ]
14  epochs: 10
15  batchsize: 8
16  learningrate: 0.001
17  save_path: ../checkpoints # 模型保存路径
18
19 inference:
20  mode: image # 推理模式，分为image和video；image模式下可推理单张图片和目录下所有图片，video调用摄像头实现推理
21  inference_model: best # 分为best和last，分别调用checkpoints下的best.pth和last.pth进行推理
22  images_path: ../data/veg_cls/bocai # 如果该路径为图片路径，则进行单张图片推理；如果该路径为目录，则对目录下所有图片进行推理
23
24 deploy:
25  chip: k230 # 芯片类型，分为“k230”和“cpu”两种
26  ptq_option: 0 # 量化类型，0为uint8，1, 2, 3, 4为uint16的不同形式
```

模型训练

进入到工程的scripts目录，执行训练代码：

```
1 | python3 main.py
```

如果训练成功，在配置文件的save_path目录下可以找到训练好的last.pth、best.pth、best.onnx、best.kmodel。

模型测试推理

设置配置文件中的inference部分，设置测试配置，执行测试代码：

```
1 | python3 inference.py
```

使用k230部署模型

环境准备和镜像编译

注意：训练环境中nncase和nncase-kpu的版本和SDK的版本要对应，nncase和nncase-kpu版本为2.4.0，SDK版本为1.1。


K230 SDK需要在Linux环境下编译，推荐使用Ubuntu Linux 20.04。

使用docker编译环境，下载[k230 sdk](#)。


```
1 | # 下载docker编译镜像
2 | docker pull ghcr.io/kendryte/k230_sdk
3 | # 可以使用以下命令确认docker镜像拉取成功
4 | docker images | grep k230_sdk
5 | # 下载sdk
6 | git clone -b v1.1 --single-branch https://github.com/kendryte/k230_sdk.git
7 | cd k230_sdk
8 | # 下载工具链，make prepare_sourcecode 会自动下载Linux和RT-Smart toolchain,
   | buildroot package, AI package等。请确保该命令执行成功并没有Error产生，下载时间和速度
   | 以实际网速为准。
9 | make prepare_sourcecode
10 | # 创建docker容器，$(pwd):$(pwd)表示系统当前目录映射到docker容器内部的相同目录下，将系统
   | 下的工具链目录映射到docker容器内部的/opt/toolchain目录下
11 | docker run -u root -it -v $(pwd):$(pwd) -v $(pwd)/toolchain:/opt/toolchain -w
   | $(pwd) ghcr.io/kendryte/k230_sdk /bin/bash
```

K230现有两种开发板，分别为CANMV-K230-V1.0（以下简称CANMV-K230）和K230-USIP-LP3-EVB（以下简称K230-EVB）。两种开发板区别如图：

K230-USIP-LP3-EVB



CANMV-K230



- 1 # 在docker中编译镜像，请耐心等待完成，不同类型开发板编译命令不同
- 2 # 如果是CANMV-K230开发板
- 3 `make CONF=k230_canmv_defconfig`
- 4 # 如果是K230-EVB开发板
- 5 `make CONF=k230_evb_defconfig`

SD卡镜像也可在嘉楠开发者社区下载：开发者社区-->资料下载-->K230-->Images

镜像烧录

CANMV-K230开发板：

编译结束后在output/k230_canmv_defconfig/images目录下可以找到编译好的镜像文件：

- 1 k230_canmv_defconfig/images
- 2 |— big-core
- 3 |— little-core
- 4 |— sysimage-sdcard.img # SD卡镜像
- 5 |— sysimage-sdcard.img.gz # SD卡镜像压缩包

CANMV-K230开发板支持SD卡镜像启动。

K230-EVB开发板：

编译结束后在output/k230_evb_defconfig/images目录下可以找到编译好的镜像文件：

- 1 k230_evb_defconfig/images
- 2 |— big-core
- 3 |— little-core
- 4 |— sysimage-sdcard.img # SD和emmc非安全启动镜像
- 5 |— sysimage-sdcard.img.gz # SD和emmc的非安全启动镜像压缩包
- 6 |— sysimage-spinor32m.img # norflash非安全启动镜像
- 7 |— sysimage-spinor32m_jffs2.img # norflash jffs2非安全启动镜像

K230 支持SDCard、eMMC、norflash等多种启动方式。

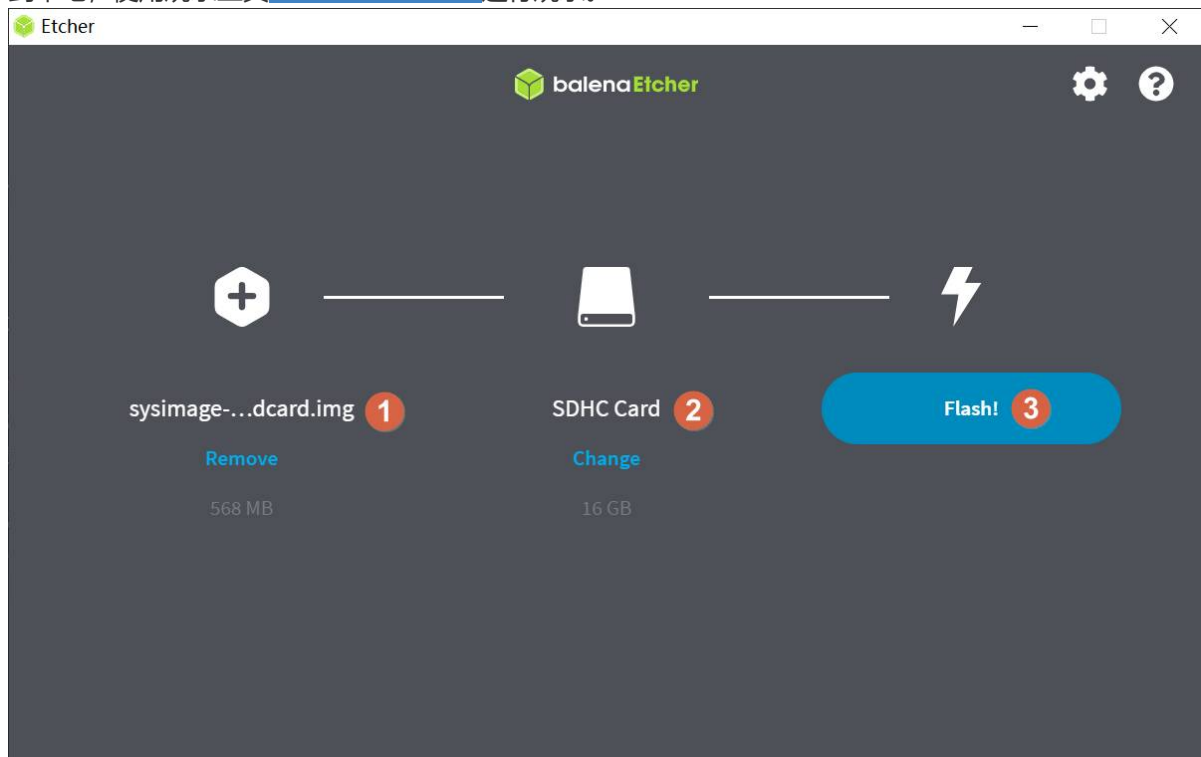
烧录TF卡

详细烧录步骤参考[K230 SDK 使用说明](#)。

Linux: 如使用Linux烧录TF卡,需要先确认SD卡在系统中的名称/dev/sdx, 并替换如下命令中的/dev/sdx

```
1 | sudo dd if=sysimage-sdcard.img of=/dev/sdx bs=1M oflag=sync
```

Windows: 如使用Windows烧录, 建议使用[the balena Etcher](#)工具。将生成的sysimage-sdcard.img下载到本地, 使用烧录工具[the balena Etcher](#)进行烧录。



其它更详细的烧录方法, 请参考[K230 SDK 使用说明](#)。

上电启动K230 EVB开发板

K230-EVB开发板上电启动

K230 EVB支持SDCard、eMMC、norflash等多种启动方式, 用户可以通过改变开板上启动拨码开关的设置, 来切换不同启动模式。为方便开发, 建议您准备一张TF卡, 并将**拨码开关切换至SD卡启动模式**, 后续可考虑将镜像文件固化至emmc中。

1. 请先**确认启动开关SW1选择在SD卡启动模式**下 (详情可参考[开机上电方式](#))
2. 将烧录完成的TF卡插入开发板TF卡槽中
3. 开发板接上电源
4. **将电源开关K1拨到ON位置**, 系统可上电启动
5. 如果您有接好串口, 可在串口中看到启动日志输出。

CanMV-K230开发板上电启动

K230 CanMV-K230开发板支持SDCard启动方式、HDMI输出显示, 因此, 需要准备一张TF卡, 此外建议准备一个HDMI显示器。

1. 将烧录完成的TF卡插入开发板TF卡槽中
2. 开发板上电, 此时, 系统可上电启动

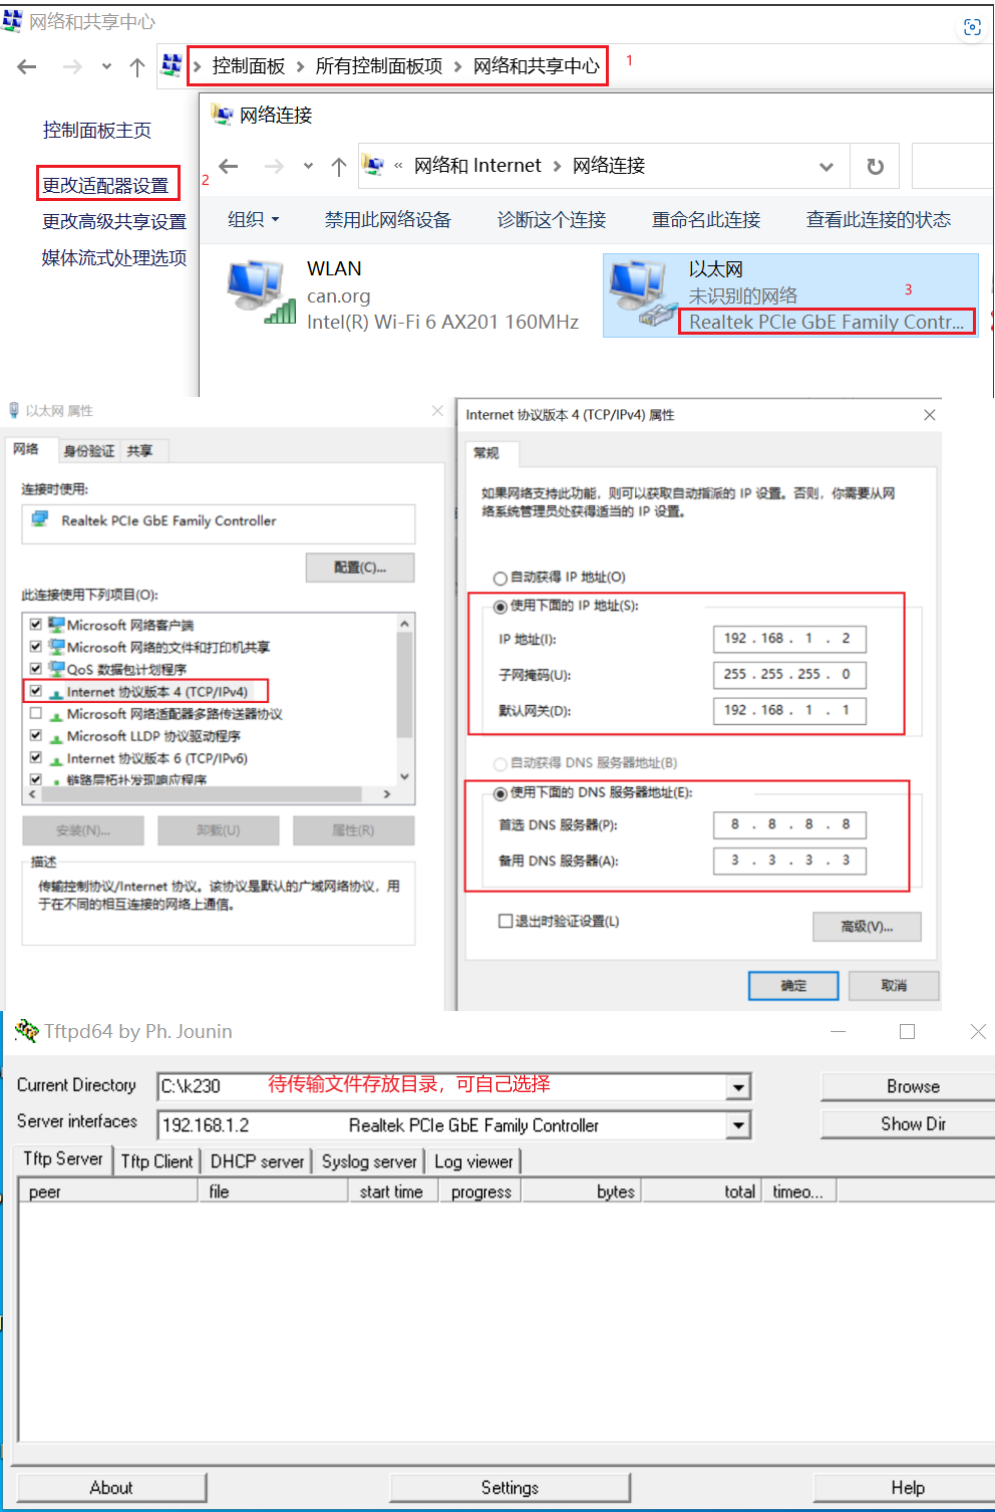
系统上电后, 默认会有**两个串口设备**, 可分别用于访问小核Linux和大核RTSmart

小核Linux默认用户名root, 密码为空。大核RTSmart系统中开机会自动启动一个应用程序, 可按 **q** 键退出至命令提示符终端。

PC和k230文件传输配置与实现


windows系统

- (1) Tftpd64安装, 在<https://bitbucket.org/phjounin/tftpd64/downloads/>下载。
- (2) MobaXterm安装: 在<https://mobaxterm.mobatek.net/download.html>下载安装。
- (2) 配置PC网络:



- (4) 开发板网络配置:

开发板上电, 电源线、网线、COM口连接线配置见文档: [K230 SDK 使用说明](#)。打开MobaXterm, 通过两路COM串口连接开发板, COM编号不固定, 较小为小核串口, 较大为大核串口。



小核进入后回车，进入如下界面，使用root登录：

```
2. COM3 (USB Serial Port (COM3))  
Welcome to Buildroot  
canaan login: root  
[root@canaan ~]#
```

大核进入后回车，进入如下界面：

```
2. COM3 (USB Serial Port (COM3)) 3. COM4 (USB Serial Port (COM4))  
msh />
```

在小核配置网络：

```
2. COM3 (USB Serial Port (COM3)) 3. COM4 (USB Serial Port (COM4))  
Welcome to Buildroot  
canaan login: root  
[root@canaan ~]#ls  
[root@canaan ~]#cd /  
[root@canaan /]#ls  
app      init      linuxrc   opt        sbin      usr  
bin      lib       lost+found proc        sharefs   var  
dev      lib64     media     root        sys  
etc      lib64xthead mnt       run         tmp  
[root@canaan /]#ifconfig eth0 192.168.1.22
```

在小核端口配置网络，和PC在同一网段即可

大小核共享存储区域：/sharefs

```
2. COM3 (USB Serial Port (COM3)) x 3. COM4 (USB Serial Port (COM4))
Welcome to Buildroot
canaan login: root
[root@canaan ~]#ls
[root@canaan ~]#cd /
[root@canaan /]#ls
app      init      linuxrc   opt       sbin      usr
bin      lib       lost+found proc      sharefs   var
dev      lib64     media     root      sys
etc      lib64xthead mnt       run       tmp
[root@canaan /]#ifconfig eth0 192.168.1.22
[root@canaan /]#cd sharefs/
[root@canaan /sharefs]#ls
```

当要从Tftpd64配置的文件中拷贝数据时，在小核界面使用如下命令：

```
1 # 192.168.1.2 为PC的局域网IP
2 tftp -g -r your_file_name 192.168.1.2
```

当将开发板文件拷贝到PC端Tftpd64配置的文件夹下时，在小核使用如下命令：

```
1 # 192.168.1.2 为PC的局域网IP
2 tftp -p -r your_file_name 192.168.1.2
```

Linux系统

在Linux系统中，PC正常连接网络，开发板可以通过网线连接PC所在网关下其他网口，通过scp命令实现文件传输。

开发板上电，进入大小核COM界面，在小核执行scp传输命令：

```
1 # 从PC拷贝文件至开发板
2 scp 用户名@域名或IP:文件所在目录 开发板目的目录
3 # 从开发板拷贝文件至PC
4 scp 开发板待拷贝目录 用户名@域名或IP:PC目的目录
```

上板code解析

完成上述开发板的准备工作后，我们可以使用C++编写自己的代码，下面就图像分类任务的示例代码进行解析。本教程给出相关图像分类任务的示例代码，并进行简单解析。

代码结构

```
1 k230_code
2 |—cmake
3   |—link.lds #链接脚本
4   |—Riscv64.cmake
5 |—k230_deploy
6   |—ai_base.cc # 模型部署基类实现
7   |—ai_base.h # 模型部署基类，封装了nncase加载、input设置、模型推理、获取output操作，后续具体任务开发只需关注模型的前处理、后处理即可
8   |—classification.cc # 图像分类code类实现
9   |—classification.h # 图像分类类定义，继承AIBase，用于加载kmodel实现图像分类任务，封装模型推理的前后处理
10  |—main.cc # 主函数，参数解析，初始化classification类示例，实现上板功能
11  |—scoped_timing.hpp # 时间测试工具
12  |—utils.cc # 工具类实现
```

```
13 | └─utils.h # 工具类，封装了图像分类任务的常用函数，包括读取二进制文件、保存图片、图  
    | 像处理、结果绘制等，用户可根据自己需求丰富该文件  
14 | └─vi_vo.h # 视频输入输出头文件  
15 | └─CMakeLists.txt # CMake脚本用于构建一个使用C/C++源文件的可执行文件，并链接到各  
    | 种库  
16 | └─build_app.sh # 编译脚本，使用交叉编译工具链编译k230_deploy工程  
17 | └─CMakeLists.txt # CMake脚本用于构建 nncase_sdk 的项目工程
```

核心代码

```
1  /**  
2   * @brief AI基类，封装nncase相关操作  
3   * 主要封装了nncase的加载、设置输入、运行、获取输出操作，后续开发demo只需要关注模型的前处  
    | 理、后处理即可  
4   */  
5  class AIBase  
6  {  
7  public:  
8      /**  
9       * @brief AI基类构造函数，加载kmodel,并初始化kmodel输入、输出  
10      * @param kmodel_file kmodel文件路径  
11      * @param debug_mode 0（不调试）、1（只显示时间）、2（显示所有打印信息）  
12      * @return None  
13      */  
14  AIBase(const char *kmodel_file,const string model_name, const int debug_mode  
    | = 1);  
15  
16      /**  
17       * @brief AI基类析构函数  
18       * @return None  
19       */  
20  ~AIBase();  
21  
22      /**  
23       * @brief 设置kmodel输入  
24       * @param buf 输入数据指针  
25       * @param size 输入数据大小  
26       * @return None  
27       */  
28  void set_input(const unsigned char *buf, size_t size);  
29  
30      /**  
31       * @brief 根据索引获取kmodel输入tensor  
32       * @param idx 输入数据指针  
33       * @return None  
34       */  
35  runtime_tensor get_input_tensor(size_t idx);  
36  
37  void set_input_tensor(size_t idx, runtime_tensor &tensor);  
38  
39      /**  
40       * @brief 初始化kmodel输出  
41       * @return None  
42       */  
43  void set_output();
```

```

44
45  /**
46   * @brief 推理kmodel
47   * @return None
48   */
49 void run();
50
51 /**
52   * @brief 获取kmodel输出，结果保存在对应的类属性中
53   * @return None
54   */
55 void get_output();
56
57
58
59 protected:
60 string model_name_;           // 模型名字
61 int debug_mode_;             // 调试模型，0（不打印），1（打印时间），2
    （打印所有）
62 vector<float*> p_outputs_;     // kmodel输出对应的指针列表
63 vector<vector<int>> input_shapes_; // {{N,C,H,W},{N,C,H,W}...}
64 vector<vector<int>> output_shapes_; // {{N,C,H,W},{N,C,H,W}...} 或 {{N,C},
    {N,C}...}}等
65 vector<int> each_input_size_by_byte_;
    // {0,layer1_length,layer1_length+layer2_length,...}
66 vector<int> each_output_size_by_byte_;
    // {0,layer1_length,layer1_length+layer2_length,...}
67 private:
68 /**
69   * @brief 首次初始化kmodel输入，并获取输入shape
70   * @return None
71   */
72 void set_input_init();
73
74 /**
75   * @brief 首次初始化kmodel输出，并获取输出shape
76   * @return None
77   */
78 void set_output_init();
79
80 // kmodel解释器，从kmodel文件构建，负责模型的加载、输入输出设置和推理
81 vector<unsigned char> kmodel_vec_; // 通过读取kmodel文件得到整个kmodel数据，用于传
    给kmodel解释器加载kmodel
82 interpreter kmodel_interp_;
83 };

```

上述代码是ai_base.h文件中AIBase类的定义代码。主要定义了kmodel解释器，kmodel的相关信息，以及输入输出设置、推理过程的接口定义。具体实现在ai_base.cc中。

```

1  /**
2   * @brief 分类任务
3   * 主要封装了对于每一帧图片，从预处理、运行到后处理给出结果的过程
4   */
5  class Classification : public AIBase
6  {

```

```

7 public:
8 /**
9  * @brief Classification构造函数, 加载kmodel,并初始化kmodel输入、输出分类阈值
10  * @param args          构建对象需要的参数, config.json文件 (包含分类阈值, kmodel路
    径等)
11  * @param debug_mode    0 (不调试)、 1 (只显示时间)、 2 (显示所有打印信息)
12  * @return None
13  */
14 Classification(string &kmodel_path, string
    &image_path, std::vector<std::string> labels, float cls_thresh, const int
    debug_mode);
15
16 /**
17  * @brief Classification构造函数, 加载kmodel,并初始化kmodel输入、输出分类阈值
18  * @param args          构建对象需要的参数, config.json文件 (包含分类阈值, kmodel路
    径等)
19  * @param isp_shape     isp输入大小 (chw)
20  * @param vaddr         isp对应虚拟地址
21  * @param paddr         isp对应物理地址
22  * @param debug_mode    0 (不调试)、 1 (只显示时间)、 2 (显示所有打印信息)
23  * @return None
24  */
25 Classification(string &kmodel_path, string
    &image_path, std::vector<std::string> labels, float cls_thresh, FrameCHWSize
    isp_shape, uintptr_t vaddr, uintptr_t paddr, const int debug_mode);
26
27 /**
28  * @brief Classification析构函数
29  * @return None
30  */
31 ~Classification();
32
33 /**
34  * @brief 图片预处理
35  * @param ori_img 原始图片
36  * @return None
37  */
38 void pre_process(cv::Mat ori_img);
39
40 /**
41  * @brief 视频流预处理 (ai2d for isp)
42  * @return None
43  */
44 void pre_process();
45
46 /**
47  * @brief kmodel推理
48  * @return None
49  */
50 void inference();
51
52 /**
53  * @brief kmodel推理结果后处理
54  * @param results 后处理之后的基于原始图像的分类结果集合
55  * @return None
56  */

```

```

57 void post_process(vector<cls_res> &results);
58
59 private:
60
61 /**
62  * @brief 计算exp
63  * @param x 自变量值
64  * @return 返回计算exp后的结果
65  */
66 float fast_exp(float x);
67
68 /**
69  * @brief 计算sigmoid
70  * @param x 自变量值
71  * @return 返回计算sigmoid后的结果
72  */
73 float sigmoid(float x);
74
75 std::unique_ptr<ai2d_builder> ai2d_builder_; // ai2d构建器
76 runtime_tensor ai2d_in_tensor_;           // ai2d输入tensor
77 runtime_tensor ai2d_out_tensor_;           // ai2d输出tensor
78 uintptr_t vaddr_;                          // isp的虚拟地址
79 FrameCHWSize isp_shape_;                  // isp对应的地址大小
80
81 float cls_thresh;      //分类阈值
82 vector<string> labels; //类别名字
83 int num_class;         //类别数
84
85 float* output;          //读取kmodel输出
86 };

```

上述代码是实现图像分类任务的类定义，主要定义图像分类模型推理的前处理、推理、后处理接口。初始化ai2d构建器实现用于图像预处理。还定义了一些图像分类任务的变量，比如类别数、标签列表、分类阈值等。具体实现在classification.cc中。

```

1 void print_usage()
2 {
3     cout << "模型推理时传参说明: "
4         << "<kmodel_path> <image_path> <debug_mode>" << endl
5         << "Options:" << endl
6         << "  kmodel_path      Kmodel的路径\n"
7         << "  image_path      待推理图片路径/摄像头(None)\n"
8         << "  debug_mode      是否需要调试, 0、1、2分别表示不调试、简单调试、详细调试\n"
9         << "\n"
10        << endl;
11 }
12
13 int main(int argc, char *argv[])
14 {
15     std::cout << "case " << argv[0] << " built at " << __DATE__ << " " <<
__TIME__ << std::endl;
16     if (argc < 4)
17     {
18         print_usage();

```

```

19         return -1;
20     }
21     // video
22     if (strcmp(argv[2], "None") == 0)
23     {
24         std::thread thread_isp(video_proc, argv);
25         while (getchar() != 'q')
26         {
27             usleep(10000);
28         }
29
30         isp_stop = true;
31         thread_isp.join();
32     }
33     // image
34     else
35     {
36         image_proc(argv);
37     }
38     return 0;
39 }

```

上述代码是main.cc文件中的一部分，主要实现解析传入参数，打印使用说明，实现两个不同分支的推理。如果输入的第二个参数是推理图像路径，则调用image_proc函数进行图像推理；如果传入的是None，则调用video_proc函数进行视频流推理。

```

1  vector<string> read_labels_txt(string &labels_txt){
2      std::vector<std::string> labels;
3      std::ifstream file(labels_txt);
4      if (!file.is_open()) {
5          std::cerr << "Failed to open the file." << std::endl;
6          return labels;
7      }
8      std::string line;
9      while (std::getline(file, line)) {
10         // 去除行末尾的换行符
11         if (!line.empty() && line[line.length() - 1] == '\n') {
12             line.erase(line.length() - 1);
13         }
14         labels.push_back(line);
15     }
16     file.close();
17     return labels;
18 }
19
20
21 void image_proc_cls(string &kmodel_path, string &image_path,vector<string>
labels,float cls_thresh ,int debug_mode)
22 {
23     //图像推理代码...
24 }
25
26 void video_proc_cls(string &kmodel_path, string &image_path,vector<string>
labels,float cls_thresh , int debug_mode)
27 {

```



```

28     //视频流推理代码...
29 }
30
31 int video_proc(char *argv[])
32 {
33     string kmodel_path = argv[1];
34     string image_path = argv[2];
35     string labels_txt=argv[3];
36     int debug_mode = std::stoi(argv[4]);
37     vector<string> labels=read_labels_txt(labels_txt);
38     float cls_thresh=0.5;
39     video_proc_cls(kmodel_path,image_path,labels,cls_thresh,debug_mode);
40     return -1;
41 }
42
43 int image_proc(char *argv[])
44 {
45     string kmodel_path = argv[1];
46     string image_path = argv[2];
47     string labels_txt=argv[3];
48     int debug_mode = std::stoi(argv[4]);
49     vector<string> labels=read_labels_txt(labels_txt);
50     float cls_thresh=0.5;
51     image_proc_cls(kmodel_path,image_path,labels,cls_thresh,debug_mode);
52     return -1;
53 }

```

上述代码是main.cc的一部分，主要实现参数解析功能，在image_proc核video_proc中将传入的参数解析出来，调用read_labels_txt函数将标签名称列表从labels.txt文件中读出作为参数传递给image_proc_cls和video_proc_cls调用。

```

1 void image_proc_cls(string &kmodel_path, string &image_path,vector<string>
  labels,float cls_thresh ,int debug_mode)
2 {
3     cv::Mat ori_img = cv::imread(image_path);
4     int ori_w = ori_img.cols;
5     int ori_h = ori_img.rows;
6     Classification cls(kmodel_path,image_path,labels,cls_thresh,debug_mode);
7     cls.pre_process(ori_img);
8     cls.inference();
9     vector<cls_res> results;
10    cls.post_process(results);
11    Utils::draw_cls_res(ori_img,results);
12    cv::imwrite("result_cls.jpg", ori_img);
13
14 }

```

上述代码是main.cc中的图像推理代码部分，首先从图片路径初始化cv::Mat对象ori_img，然后初始化Classification实例cls，调用cls预处理函数pre_process，推理函数reference，后处理函数post_process，最后调用utils.h中的draw_cls_res将结果绘制在图片上并保存为result_cls.jpg。如您需要修改前后处理部分，可在classification.cc中进行修改，如您想添加其他工具方法，可在utils中定义，并在utils.cc中实现。

```

1 void video_proc_cls(string &kmodel_path, string &image_path,vector<string>
  labels,float cls_thresh , int debug_mode)
2 {
3     vivcap_start();
4
5     k_video_frame_info vf_info;
6     void *pic_vaddr = NULL;          //osd
7
8     memset(&vf_info, 0, sizeof(vf_info));
9
10    vf_info.v_frame.width = osd_width;
11    vf_info.v_frame.height = osd_height;
12    vf_info.v_frame.stride[0] = osd_width;
13    vf_info.v_frame.pixel_format = PIXEL_FORMAT_ARGB_8888;
14    block = vo_insert_frame(&vf_info, &pic_vaddr);
15
16    // alloc memory
17    size_t paddr = 0;
18    void *vaddr = nullptr;
19    size_t size = SENSOR_CHANNEL * SENSOR_HEIGHT * SENSOR_WIDTH;
20    int ret = kd_mpi_sys_mmz_alloc_cached(&paddr, &vaddr, "allocate",
  "anonymous", size);
21    if (ret)
22    {
23        std::cerr << "physical_memory_block::allocate failed: ret = " << ret
  << ", errno = " << strerror(errno) << std::endl;
24        std::abort();
25    }
26
27    Classification cls(kmodel_path,image_path,labels,cls_thresh,
  {SENSOR_CHANNEL, SENSOR_HEIGHT, SENSOR_WIDTH}, reinterpret_cast<uintptr_t>
  (vaddr), reinterpret_cast<uintptr_t>(paddr), debug_mode);
28
29    vector<cls_res> results;
30
31    while (!isp_stop)
32    {
33        ScopedTiming st("total time", debug_mode);
34
35        {
36            ScopedTiming st("read capture", debug_mode);
37            // VICAP_CHN_ID_1 out rgb888p
38            memset(&dump_info, 0 , sizeof(k_video_frame_info));
39            ret = kd_mpi_vicap_dump_frame(vicap_dev, VICAP_CHN_ID_1,
  VICAP_DUMP_YUV, &dump_info, 1000);
40            if (ret) {
41                printf("sample_vicap...kd_mpi_vicap_dump_frame failed.\n");
42                continue;
43            }
44        }
45
46        {
47            ScopedTiming st("isp copy", debug_mode);
48            // 从vivcap中读取一帧图像到dump_info
49

```

```

50         auto vbvaddr =
kd_mpi_sys_mmap_cached(dump_info.v_frame.phys_addr[0], size);
51         memcpy(vaddr, (void *)vbvaddr, SENSOR_HEIGHT * SENSOR_WIDTH *
3); // 这里以后可以去掉, 不用copy
52         kd_mpi_sys_munmap(vbvaddr, size);
53     }
54
55     results.clear();
56
57     cls.pre_process();
58     cls.inference();
59
60     cls.post_process(results);
61
62     cv::Mat osd_frame(osd_height, osd_width, CV_8UC4, cv::Scalar(0, 0,
0, 0));
63     cv::Mat osd_frame_tmp;
64
65     {
66         ScopedTiming st("osd draw", debug_mode);
67         Utils::draw_cls_res(osd_frame, results, {osd_width, osd_height},
{SENSOR_WIDTH, SENSOR_HEIGHT});
68         cv::flip(osd_frame, osd_frame_tmp, 0);
69         cv::flip(osd_frame_tmp, osd_frame, 1);
70     }
71
72
73     {
74         ScopedTiming st("osd copy", debug_mode);
75         memcpy(pic_vaddr, osd_frame.data, osd_width * osd_height * 4);
76         //显示通道插入帧
77         kd_mpi_vo_chn_insert_frame(osd_id+3, &vf_info); //K_VO_OSD0
78         printf("kd_mpi_vo_chn_insert_frame success \n");
79
80         ret = kd_mpi_vicap_dump_release(vicap_dev, VICAP_CHN_ID_1,
&dump_info);
81         if (ret) {
82             printf("sample_vicap...kd_mpi_vicap_dump_release failed.\n");
83         }
84     }
85 }
86
87 vo_osd_release_block();
88 vivcap_stop();
89
90
91 // free memory
92 ret = kd_mpi_sys_mmz_free(paddr, vaddr);
93 if (ret)
94 {
95     std::cerr << "free failed: ret = " << ret << ", errno = " <<
strerror(errno) << std::endl;
96     std::abort();
97 }
98 }

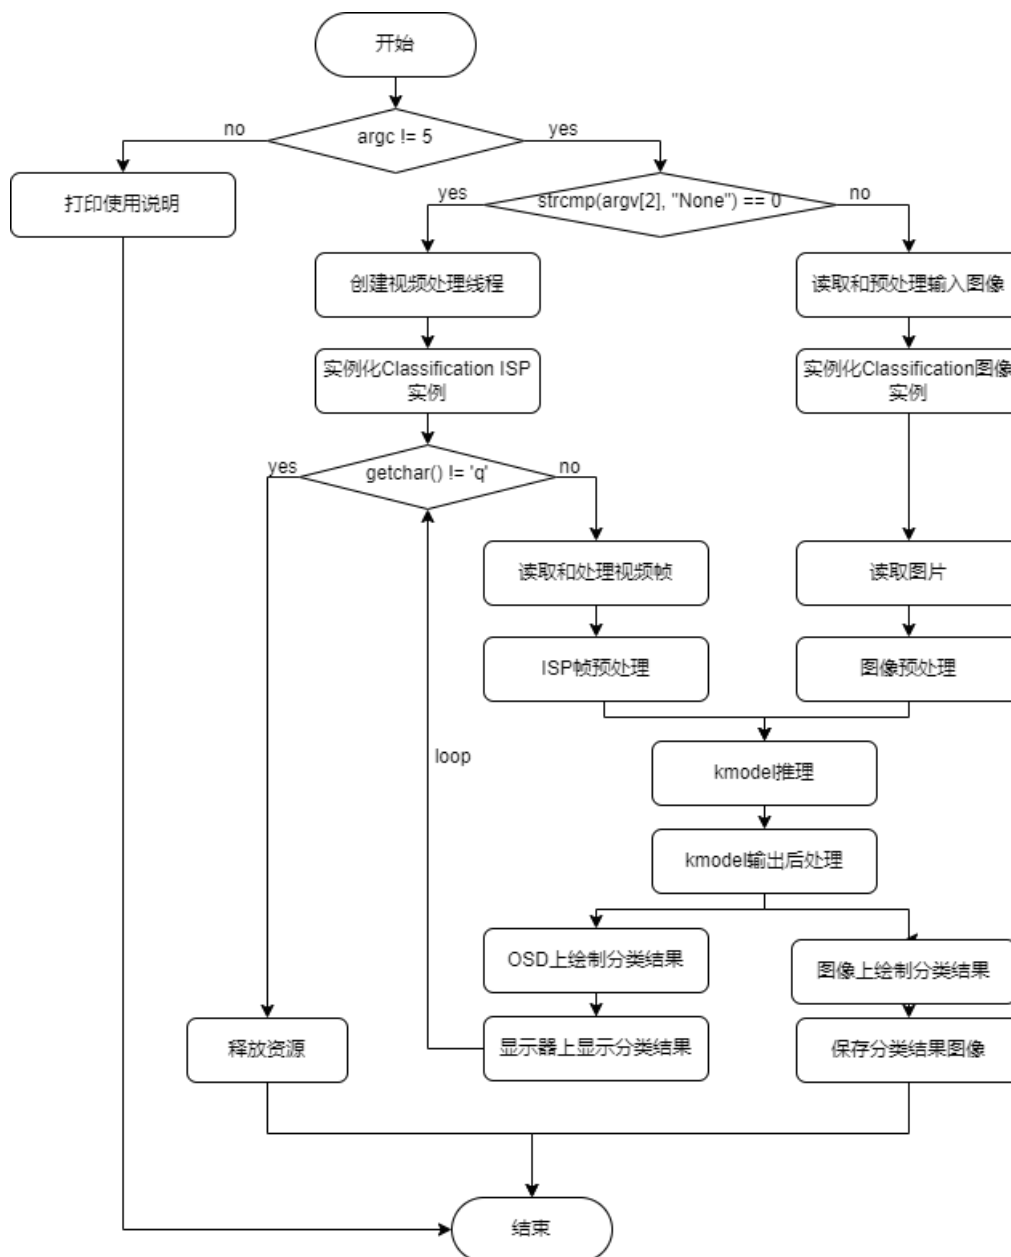
```

上述代码是main.cc中对视频流进行分类操作的部分。下面是详细解析：

- vivcap_start()和 vivcap_stop()函数用于开始和停止视频捕获；
- k_video_frame_info vf_info定义一个 k_video_frame_info 结构体变量 vf_info，用于存储视频帧的信息；
- void *pic_vaddr = NULL定义一个 void 指针 pic_vaddr，用于存储 OSD（On-Screen Display）图像数据；
- memset(&vf_info, 0, sizeof(vf_info))将 vf_info 结构体的内存初始化为零，然后设置视频帧的信息，包括宽度、高度、stride 和像素格式等；
- block = vo_insert_frame(&vf_info, &pic_vaddr)调用 vo_insert_frame 函数插入帧数据；
kd_mpi_sys_mmz_alloc_cached 函数分配一块内存，用于存储图像数据，paddr 存储物理地址，
vaddr 存储虚拟地址，size 是内存块大小；
- 创建 Classification 对象 cls，用于实现分类任务；
- 创建一个空的 results 向量，用于存储分类结果。
- 进入循环，只要 isp_stop 标志不为真时：
 - a. 使用 kd_mpi_vicap_dump_frame 从视频捕获设备中获取一帧图像数据，存储在 dump_info 中；
 - b. 通过 kd_mpi_sys_mmap_cached 和 memcpy 将捕获的图像数据复制到之前分配的内存块中；
 - c. 清空 results 向量，调用 cls 的预处理方法、推理方法和后处理方法，对图像进行分类；
 - d. 利用分类结果，在 OSD 图像上绘制分类信息；
 - e. 使用 memcpy 将 OSD 图像数据复制到之前分配的 OSD 数据块中；
 - f. 通过 kd_mpi_vo_chn_insert_frame 将 OSD 图像插入到显示通道；
 - g. 通过 kd_mpi_vicap_dump_release 释放之前捕获的图像。
- 循环结束后，释放 OSD 相关的资源，通过 vo_osd_release_block() 和 vivcap_stop() 函数；
- 使用 kd_mpi_sys_mmz_free 释放之前分配的内存块。

通过上述代码实现图像分类任务的视频流推理。

代码流程图



k230_code/k230_deploy/CMakeLists.txt脚本说明

```

1  set(src main.cc utils.cc ai_base.cc classification.cc)
2  set(bin main.elf)
3
4  include_directories(${PROJECT_SOURCE_DIR})
5  include_directories(.)
6
7  include_directories(${nncase_sdk_root}/riscv64/rvvlb/include)
8  include_directories(${k230_sdk}/src/big/mpp/userapps/api/)
9  include_directories(${k230_sdk}/src/big/mpp/include)
10 include_directories(${k230_sdk}/src/big/mpp/include/comm)
11 include_directories(${k230_sdk}/src/big/mpp/userapps/sample/sample_vo)
12 link_directories(${nncase_sdk_root}/riscv64/rvvlb/)
13
14 add_executable(${bin} ${src})
15 target_link_libraries(${bin} -Wl,--start-group rvv Nncase.Runtime.Native
nncase.rt_modules.k230 functional_k230 sys vicap vb cam_device cam_engine

```

```

16  hal oslayer ebase fpga isp_drv binder auto_ctrl common cam_caldb isi 3a
    buffer_management cameric_drv video_in virtual_hal start_engine cmd_buffer
17  switch cameric_reg_drv t_database_c t_mxml_c t_json_c t_common_c vo
    connector sensor atomic dma -wl,--end-group)
18
19  target_link_libraries(${bin} opencv_imgproc opencv_imgcodecs opencv_core zlib
    libjpeg-turbo libopenjp2 libpng libtiff libwebp csi_cv)
20  install(TARGETS ${bin} DESTINATION bin)

```

这是k230_code/k230_deploy目录下的CMakeLists.txt脚本，设置编译的C++文件和生成的elf可执行文件名称，由下面：

```

1  set(src main.cc utils.cc ai_base.cc classification.cc)
2  set(bin main.elf)

```

```

1  • include_directories(${PROJECT_SOURCE_DIR}): 添加项目的根目录到头文件搜索路径中。
2  • include_directories(${nncase_sdk_root}/riscv64/rvvlib/include): 添加 nncase
    RISC-V 向量库的头文件目录。
3  • include_directories(${k230_sdk}/src/big/mpp/userapps/api/): 添加 k230 SDK 中
    的用户应用程序 API 头文件目录。
4  • include_directories(${k230_sdk}/src/big/mpp/include): 添加 k230 SDK 的一般头文
    件目录。
5  • include_directories(${k230_sdk}/src/big/mpp/include/comm): 添加与通信相关的头文
    件目录。
6  • include_directories(${k230_sdk}/src/big/mpp/userapps/sample/sample_vo): 添加
    示例 VO（视频输出）应用程序头文件目录。

```

```

1  link_directories(${nncase_sdk_root}/riscv64/rvvlib/): 添加链接器搜索路径，指向
    nncase RISC-V 向量库的目录。
2  add_executable(${bin} ${src}): 创建一个可执行文件，将之前设置的源文件列表作为输入。
3  target_link_libraries(${bin} ...): 设置可执行文件需要链接的库。列表中列出了各种库，包括
    nncase 相关的库、k230 SDK 的库，以及其他一些库。
4  target_link_libraries(${bin} opencv_imgproc opencv_imgcodecs opencv_core zlib
    libjpeg-turbo libopenjp2 libpng libtiff libwebp csi_cv): 将一些 OpenCV 相关的库
    和其他一些库链接到可执行文件中。
5  install(TARGETS ${bin} DESTINATION bin): 安装生成的可执行文件到指定的目标路径（bin
    目录）中。

```

上述是k230_code/k230_deploy目录下的CMakeLists.txt脚本说明。

k230_code/CMakeLists.txt脚本说明

```

1  cmake_minimum_required(VERSION 3.2)
2  project(nncase_sdk C CXX)
3
4  set(nncase_sdk_root "${PROJECT_SOURCE_DIR}/../../nncase/")
5  set(k230_sdk ${nncase_sdk_root}/../../../)
6  set(CMAKE_EXE_LINKER_FLAGS "-T ${PROJECT_SOURCE_DIR}/cmake/link.ld --
    static")
7
8  # set opencv
9  set(k230_opencv ${k230_sdk}/src/big/utils/lib/opencv)
10 include_directories(${k230_opencv}/include/opencv4/)

```

```

11 link_directories(${k230_opencv}/lib ${k230_opencv}/lib/opencv4/3rdparty)
12
13 # set mmz
14 link_directories(${k230_sdk}/src/big/mpp/userapps/lib)
15
16 # set nncase
17 include_directories(${nncase_sdk_root}/riscv64)
18 include_directories(${nncase_sdk_root}/riscv64/nncase/include)
19 include_directories(${nncase_sdk_root}/riscv64/nncase/include/nncase/runtime)
20 link_directories(${nncase_sdk_root}/riscv64/nncase/lib/)
21
22 add_subdirectory(k230_deploy)

```

这是k230_code目录下的CMakeLists.txt脚本。该脚本重点关注如下部分

```

1 set(nncase_sdk_root "${PROJECT_SOURCE_DIR}/../../nncase/"):设置nncase目录
2 set(k230_sdk ${nncase_sdk_root}/../../../):设置k230_sdk的目录, 当前是从nncase目录
  的三级父目录得到
3 set(CMAKE_EXE_LINKER_FLAGS "-T ${PROJECT_SOURCE_DIR}/cmake/link.lds --
  static"):设置链接脚本路径, 链接脚本放于k230_code/cmake下
4 ...
5 add_subdirectory(k230_deploy): 添加待编译的工程子目录, 如您要编译自己的工程, 可以更换该
  行

```

以上是k230_code目录下的CMakeLists.txt脚本说明。

k230_code/build_app.sh脚本说明

```

1 #!/bin/bash
2 set -x
3
4 # set cross build toolchain
5 # 将交叉编译工具链的路径添加到系统的 PATH 环境变量中, 以便在后续的命令中使用。该工具链是使
  用的大核编译工具链。
6 export PATH=$PATH:/opt/toolchain/riscv64-linux-musleabi_for_x86_64-pc-linux-
  gnu/bin/
7
8 clear
9 rm -rf out
10 mkdir out
11 pushd out
12 cmake -DCMAKE_BUILD_TYPE=Release \
13       -DCMAKE_INSTALL_PREFIX=`pwd` \
14       -DCMAKE_TOOLCHAIN_FILE=cmake/Riscv64.cmake \
15       ..
16
17 make -j && make install
18 popd
19
20 # 生成的main.elf可以在k230_code目录下的k230_bin文件夹下找到
21 k230_bin=`pwd`/k230_bin
22 rm -rf ${k230_bin}
23 mkdir -p ${k230_bin}
24
25 if [ -f out/bin/main.elf ]; then

```



```
26 | cp out/bin/main.elf ${k230_bin}
27 | fi
```

AI代码编译

将项目中的k230_code文件夹拷贝到k230_sdk目录下的src/big/nncase下，执行编译脚本，将C++代码编译成main.elf可执行文件。K230现有两种开发板，两种开发板编译命令不同，请注意区分。

CANMV-K230开发板

如果编译可以在CANMV-K230开发板执行的elf文件：

```
1 | # 在k230_SDK目录下执行
2 | make CONF=k230_canmv_defconfig prepare_memory
3 | # 回到当前项目目录下
4 | ./build_app.sh
```

K230-EVB开发板

如果编译可以在K230-EVB开发板执行的elf文件：

```
1 | # 在k230_SDK目录下执行
2 | make CONF=k230_evb_defconfig prepare_memory
3 | # 回到当前项目目录下
4 | ./build_app.sh
```

若权限不够，可使用如下代码赋予相关权限：

```
1 | chmod +x build_app.sh
2 | ./build_app.sh
```

文件拷贝

按照上文第4节配置好文件传输，在MobaXterm上的小核界面进入/sharefs，将训练得到的checkpoints文件夹下kmodel文件、gen文件夹下labels.txt文件的和编译得到的main.elf文件拷贝到开发板的sharefs目录下新建的项目文件夹test_cls下。同时拷贝一张待推理的图片。

```
1 | test_cls
2 | |—best.kmodel
3 | |—labels.txt
4 | |—main.elf
5 | |—001.jpg
```

模型板上运行

在大核COM口界面执行main.elf实现蔬菜分类。


如进行静态图推理，执行下述代码(注意：代码需在大核下执行，文件拷贝需在小核下完成)：

```
1 # "模型推理时传参说明: "  
2 # "<kmodel_path> <image_path> <labels_txt> <debug_mode>"  
3 # "Options:"  
4 # " kmodel_path      Kmodel的路径\n"  
5 # " image_path       待推理图片路径/摄像头(None)\n"  
6 # " labels_txt       类别标签文件路径\n"  
7 # " debug_mode       是否需要调试, 0、1、2分别表示不调试、简单调试、详细调试\n"  
8 main.elf best.kmodel 001.jpg labels.txt 2
```

如执行摄像头视频流推理, 执行下述代码:

```
1 | main.elf best.kmodel None labels.txt 2
```

上板部署效果



```
msh /sharefs/test_cls>main.elf best.kmodel 001.jpg labels.txt 0  
case main.elf built at Aug 14 2023 16:22:14  
class: bocai, score: 1.00  
msh /sharefs/test_cls>
```

工具

烧录工具the balena Etcher: <https://etcher.balena.io/>

局域网文件传输工具Tftpd64: <https://bitbucket.org/phjounin/tftpd64/downloads/>

MobaXterm下载地址: <https://mobaxterm.mobatek.net/download.html>

参考

k230_sdk github: https://github.com/kendryte/k230_sdk

k230_sdk_doc github: [k230_sdk 使用说明](#)

k230_sdk gitee: https://gitee.com/kendryte/k230_sdkc

nncase github: [kendryte/nncase: Open deep learning compiler stack for Kendryte AI accelerator \(github.com\)](#)